Universidad Alfonso X el Sabio

Ejercicio de feedback 2

Máster en Inteligencia Artificial

Detección Inteligente de Arritmias con Datos de ECG y Aprendizaje Automático

Tania Évora Vargas Martínez

---

19 de enero de 2026

Índice

1. Introducción **1**

1.1. Objetivos 1

1.2. Estructura del informe 1

2. Análisis Exploratorio de Datos **1**

2.1. Descripción del dataset 2

2.2. Distribución de clases 2

2.3. Estadística descriptiva global 2

2.4. Análisis morfológico de las señales 4

3. Reducción de Dimensionalidad (PCA) **4**

3.1. Estrategia de preprocesamiento 4

3.2. Varianza Explicada 5

3.3. Proyección visual y análisis de separabilidad 5

4. Modelos de Clasificación **6**

4.1. Resultados de los modelos 6

4.2. Comparación de modelos 8

5. Teorema de Bayes **8**

5.1. Probabilidades marginales 8

5.2. Definición del patrón observable 9

5.3. Probabilidades condicionales 9

5.4. Análisis de resultados 9

6. Conclusiones **10**

6.1. Líneas futuras 11

7. Referencias **11**

8. Anexos **12**

A. Morfología de las señales 12

B. Análisis detallado de la proyección PCA por clase 12

1. Introducción

Este trabajo aborda la clasificación automática de latidos cardíacos utilizando el *ECG Heartbeat Categorization Dataset*, un conjunto de datos derivado de las bases clínicas MIT-BIH Arrhythmia Dataset y el PTB Diagnostic ECG Database. El análisis se plantea bajo el supuesto práctico de integrar este modelo en dispositivos tipo *smartwatch* para la monitorización preventiva de personas mayores de 60 años.

1.1. Objetivos

El objetivo general es desarrollar un clasificador que distinga latidos normales y anómalos. Para ello, se establecen los siguientes objetivos específicos:

- Explorar la estructura del conjunto de datos y las características de las señales.
- Aplicar técnicas de reducción de dimensionalidad (PCA) para facilitar el análisis visual de las clases.
- Entrenar y comparar modelos de aprendizaje automático para la clasificación de latidos.
- Estimar probabilidades mediante el Teorema de Bayes para interpretar los resultados desde una perspectiva clínica.

1.2. Estructura del informe

El documento comienza con el análisis exploratorio de datos (EDA), centrado en la distribución de clases y la estadística descriptiva. A continuación, se aplica el Análisis de Componentes Principales (PCA) para estudiar la separabilidad de los datos. En las secciones posteriores, se detalla el entrenamiento de los modelos de clasificación y se aplica el Teorema de Bayes para el cálculo de probabilidades. Finalmente, se presentan las conclusiones derivadas del estudio.

2. Análisis Exploratorio de Datos

En esta sección se presenta el análisis exploratorio de datos (EDA) con el fin de comprender la estructura del conjunto de datos, identificar patrones relevantes y detectar posibles anomalías que puedan influir en el modelado posterior. Se describen las características del dataset, la distribución de las clases y los principales estadísticos descriptivos de las señales ECG.

2.1. Descripción del dataset

Si bien el *ECG Heartbeat Categorization Dataset* combina registros de MIT-BIH y PTB, para este trabajo se utilizan exclusivamente los datos procedentes de MIT-BIH. Este subconjunto cuenta con 109 446 registros de latidos cardíacos, divididos en:

- **Conjunto de entrenamiento**: 87 554 registros
- **Conjunto de prueba**: 21 892 registros

Cada registro representa un latido cardíaco descrito por 187 valores numéricos correspondientes a la señal de ECG muestreada a 125 Hz. Además, cada latido cuenta con una etiqueta de clase que indica el tipo de latido según la clasificación clínica:

- **Clase 0**: Latido normal (N)
- **Clase 1**: Latido supraventricular (S)
- **Clase 2**: Latido ventricular (V)
- **Clase 3**: Latido de fusión (F)
- **Clase 4**: Ruido o señal no clasificable (Q)

Todos los latidos han sido previamente segmentados y normalizados al rango [0, 1], lo que facilita el análisis estadístico y el entrenamiento de los modelos. La revisión inicial de los datos confirma que todos los valores son numéricos y no se detectaron valores nulos ni inconsistencias evidentes.

2.2. Distribución de clases

El análisis de la variable objetivo revela un **desbalance significativo** entre las clases. Como se observa en la Figura 1 (y su agrupación binaria, Figura 2), el 82.77 % de los registros corresponden a latidos normales (clase 0), mientras que el conjunto de anomalías (clases 1, 2, 3 y 4) representan únicamente el 17.23 % de los datos.

Este fenómeno es coherente con los escenarios clínicos reales, donde las arritmias son casos menos frecuentes en comparación con los latidos normales. Desde el punto de vista del modelado, este desbalance puede afectar al rendimiento de los clasificadores, ya que los modelos tienden a favorecer a la clase mayoritaria para minimizar el error global.

2.3. Estadística descriptiva global

Para entender la naturaleza de las señales ECG, se realizó un análisis estadístico de las 187 variables temporales que componen cada latido. Este análisis confirma, en primer lugar, la normalización de los datos, situando todas las amplitudes en el rango [0, 1].

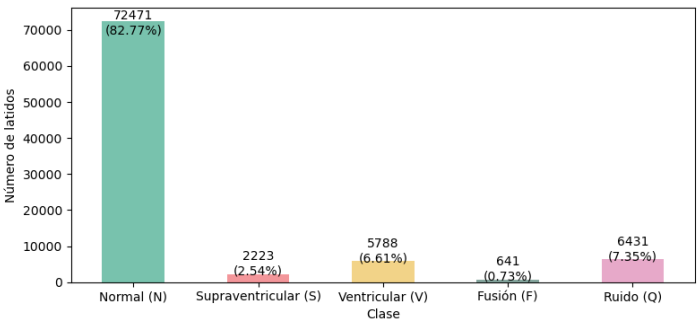


Figura 1: Distribución original (5 clases)

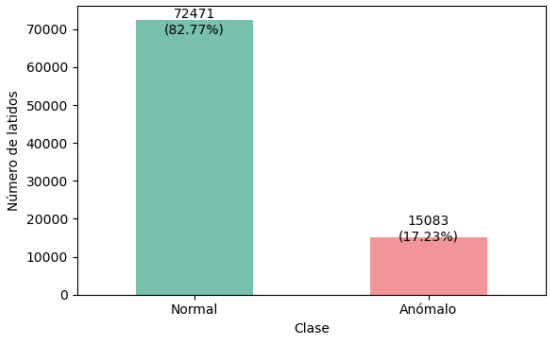


Figura 2: Distribución binaria

Al desglosar el análisis por cada tipo de latido, se observan diferencias en la tendencia central y la dispersión. Como se detalla en la Tabla 1, la media varía según la clase: la clase Fusión presenta los valores más bajos, lo que indica señales con menor energía promedio. En contraste, las clases Ventricular y Ruido alcanzan las medias más altas.

La variabilidad, medida a través de la desviación estándar, es máxima en la clase Ventricular, reflejando mayor inestabilidad. Por su parte, las clases Normal y Supraventricular muestran variabilidad intermedia y similar entre sí ($\approx 0{,}16$).

Clase	**Media**	**Desv. Est.**	**Mínimo**	**Máximo**	**Asimetría**	**Curtosis**
Normal	0.162	0.168	0.000	1.000	3.438	33.774
Supraventricular	0.195	0.162	0.000	1.000	1.396	3.949
Ventricular	0.244	0.213	0.000	1.000	1.416	3.930
Fusión	0.107	0.107	0.000	1.000	8.202	121.720
Ruido	0.251	0.134	0.000	1.000	20.656	1576.077

Tabla 1: Comparación de estadísticos.

En cuanto a las medidas de forma, aunque todas las clases presentan asimetrías positivas, la magnitud difiere drásticamente. Las clases Supraventricular y Ventricular muestran distribuciones más aplanadas (menor curtosis), mientras que la clase Normal presenta una alta concentración de valores en torno a la media. El caso extremo es la clase Ruido, cuya curtosis desorbitada refleja una señal plana interrumpida por picos marcados.

Esta variabilidad se traduce visualmente en la Figura 3, donde se representa cada clase con un código de color. Las clases Normal (verde) y Fusión (verde oscuro) se caracterizan por cajas estrechas y las medias más bajas; destaca en la Normal la densidad de valores atípicos, consecuencia de su baja varianza. Por el contrario, las clases Ventricular (amarillo) y Ruido (rosa) presentan cajas amplias y medianas elevadas, mientras que la clase Supraventricular (rojo) muestra un comportamiento intermedio. A pesar de estas diferencias, el gráfico revela un solapamiento entre los rangos de todos los tipos de latidos.

2.4. Análisis morfológico de las señales

La Figura 4 muestra el perfil temporal promedio para cada una de las cinco clases, calculado mediante la media punto a punto de las señales. La clase **Normal** (verde) presenta una morfología limpia, con un pico inicial pronunciado seguido de una rápida caída que se estabiliza hasta converger en 0 cerca de la muestra 150. La clase **Supraventricular** (rojo) guarda similitudes con la Normal en su fase inicial, pero se distingue por presentar oscilaciones más marcadas en la zona intermedia.

Por el contrario, la clase **Ventricular** (amarillo) es la más diferente, ya que mantiene una amplitud elevada durante más tiempo, con una convergencia más lenta, que no se completa hasta pasada la muestra 175. La clase **Fusión** (verde oscuro) muestra una morfología irregular, de menor energía, caracterizada por un repunte de amplitud entre las muestras 50 y 75 que rompe el patrón de descenso. Finalmente, la clase **Ruido** (rosa) presenta un perfil errático con un doble pico, una anomalía que podría facilitar su diferenciación respecto a un latido Normal.

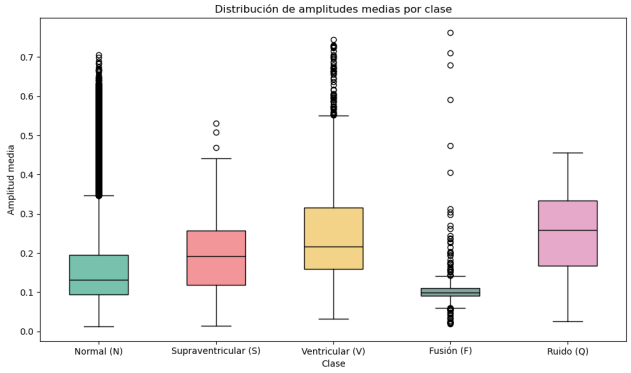


Figura 3: Amplitud media de los latidos

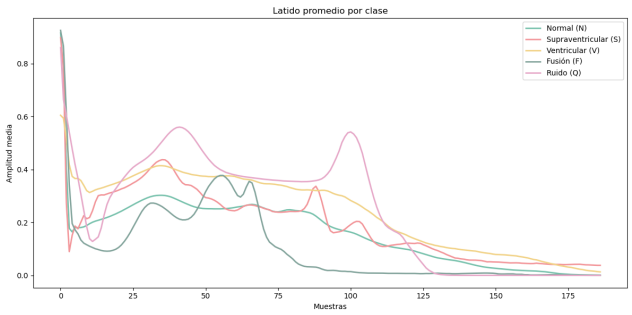


Figura 4: Latido promedio por clase

Debe tenerse en cuenta que, al tratarse de promedios, estas representaciones suavizan las variaciones individuales. Para observar la morfología típica de cada clase, se adjunta en el Anexo A una visualización con ejemplos de latidos individuales por clase.

3. Reducción de Dimensionalidad (PCA)

En esta sección se describe lo obtenido al aplicar el Análisis de Componentes Principales (PCA) con el fin de explorar la estructura de los datos en un espacio de menor dimensión y evaluar visualmente la separabilidad entre las clases.

3.1. Estrategia de preprocesamiento

Contrario a la práctica común en PCA de estandarizar los datos, en este caso se opta por **mantener la normalización original [0, 1]**. Al tratarse de una señal temporal donde todas las columnas comparten la misma unidad de medida, una re-estandarización podría distorsionar

la morfología de las ondas ECG y amplificar el ruido, eliminando información relevante para distinguir entre latidos normales y anómalos.

3.2. Varianza Explicada

La Figura 5 muestra la varianza explicada por los 20 primeros componentes. Se observa una caída pronunciada tras el primer componente, lo que indica que una gran parte de la información se concentra en una única dimensión.

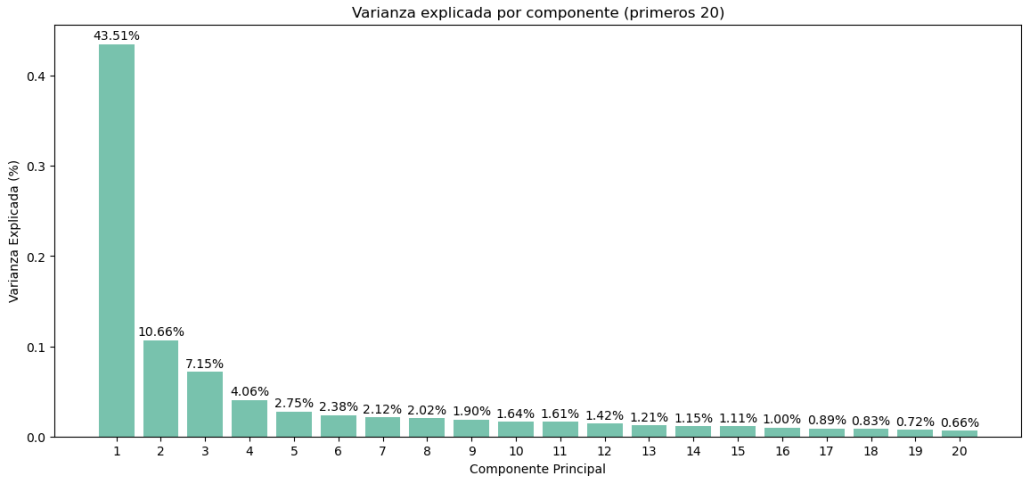


Figura 5: Varianza explicada por los primeros 20 componentes principales.

Para valorar la retención de información, la Tabla 2 resume la varianza acumulada. Los dos primeros componentes capturan en conjunto el 54.17 % de la varianza y para alcanzar un 90 % de la información serían necesarios 23 componentes.

Componentes	1	2	10	23	35
Varianza acumulada	43.51 %	54.17 %	78.19 %	90.00 %	95.00 %

Tabla 2: Varianza explicada por componentes principales

3.3. Proyección visual y análisis de separabilidad

Al proyectar los datos sobre las dos primeras componentes principales, que explican el **54.17 %** de la varianza total, se obtiene la representación bidimensional mostrada en la Figura 6.

La gráfica muestra un **solapamiento** entre las clases. La clase Normal (verde) actúa como fondo que ocupa practicamente todo el espacio. Este comportamiento confirma visualmente el desbalance de clases previamente identificado, además de la dificultad de separación sugerida en el análisis de amplitud (Figura 3). Aunque a simple vista predomina este solapamiento, se incluye en el Anexo B un análisis desglosado de cada clase para analizar su estructura.

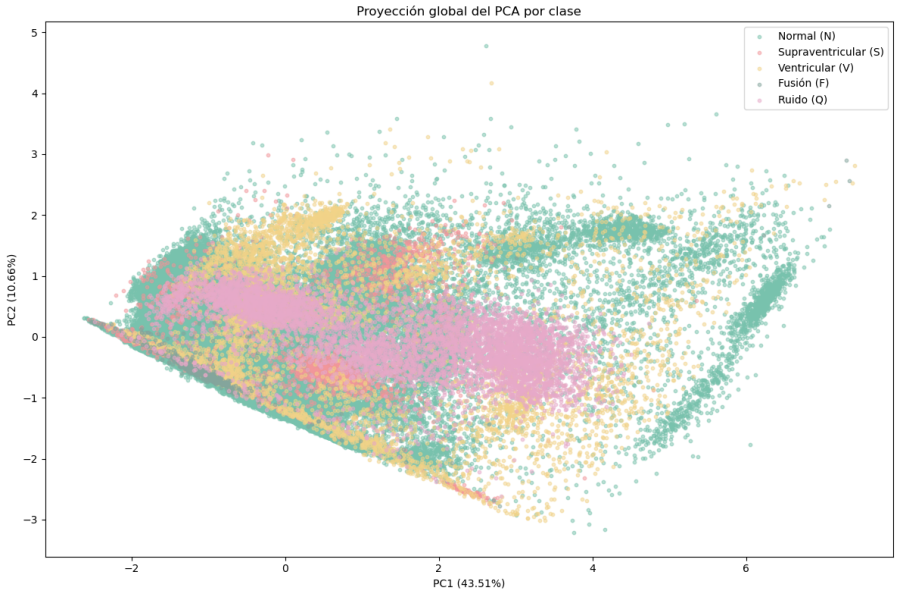


Figura 6: Proyección PCA en 2D de los datos

4. Modelos de Clasificación

En esta sección se evalúa el rendimiento de cuatro modelos para distinguir entre latidos normales y anómalos. El entrenamiento se realiza sobre el conjunto de datos de entrenamiento y se validan los resultados sobre el conjunto de prueba. Los modelos entrenados son: Regresión Logística, Árbol de Decisión, Naive Bayes y Red Neuronal Multicapa (MLP).

Para la evaluación, se prioriza la **Sensibilidad (Recall)** como métrica crítica, dado el desbalance de clases observado. En este contexto, un falso negativo (anomalía no detectada) implica un riesgo grave para la salud del paciente, mientras que un falso positivo se considera un error gestionable. También se analiza el **F1-Score** para medir el equilibrio global entre precisión y recall, y se examinan las matrices de confusión para identificar los errores de cada modelo.

4.1. Resultados de los modelos

A continuación se explican los resultados obtenidos por cada modelo, analizando sus métricas y el comportamiento observado.

- **Regresión Logística**: Obtiene una exactitud (*accuracy*) del 90.51 %; sin embargo, su recall es bajo (54.72 %), lo que indica que solo detecta cerca de la mitad de las anomalías reales. Este comportamiento es consecuencia del desbalance observado en el EDA, el modelo tiende a predecir la mayoría de latidos como normales para minimizar el error global. Su precisión del 84.88 % sugiere que cuando predice una anomalía suele acertar, pero deja una gran cantidad de casos sin detectar. En la Figura 7 (tonos azules) se aprecia cómo la mayor concentración de aciertos (color oscuro) se limita a la clase normal.
- **Árbol de Decisión**: Muestra un buen rendimiento, con una exactitud del 96.11 % y un

recall del 88.61 %. Esto indica que el modelo es capaz de identificar patrones no lineales y establecer umbrales que distinguen mejor las arritmias. Su F1-Score (88.71 %) refleja un buen equilibrio y una ventaja adicional es su interpretabilidad, ya que se basa en reglas condicionales fácilmente visualizables, lo que es favorable en contextos clínicos. La Figura 8 (tonos verdes) muestra una mejora en la detección de anomalías respecto a la Regresión Logística.

- **Naive Bayes**: Presenta los peores resultados, con una exactitud del 81.01 % y un F1-Score del 47.17 %. Este modelo asume independencia entre características, una premisa irreal para señales temporales como el ECG donde las 187 muestras están fuertemente correlacionadas. Al ignorar esta dependencia, se producen errores importantes. Tal como se observa en la Figura 9, (tonos naranjas), aunque detecta correctamente gran parte de los latidos normales, comete numerosos errores al clasificar anomalías, mostrando una dispersión de fallos tanto en falsos positivos como negativos.

- **Red Neuronal Multicapa (MLP)**: Es el modelo que obtiene el mejor rendimiento, ya que aprende patrones complejos mediante capas ocultas (arquitectura de 64 y 32 neuronas), alcanza una exactitud del 97.86 %, una precisión del 96.99 % y un recall del 90.41 %. Como se observa en la Figura 10 (tonos morados), es el modelo que más anomalías detecta y el que presenta la diagonal principal más definida, minimizando los errores.

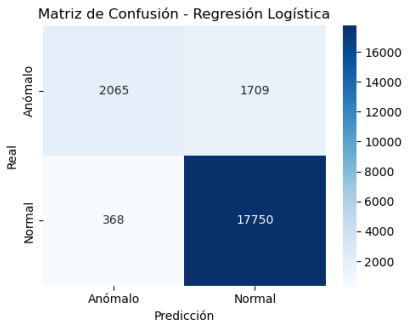


Figura 7: Regresión Logística

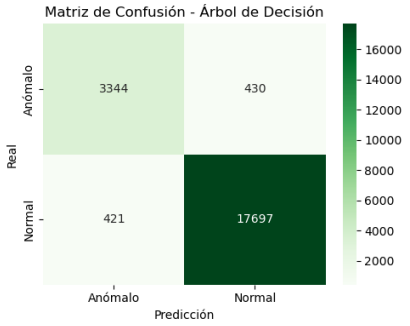


Figura 8: Árbol de Decisión

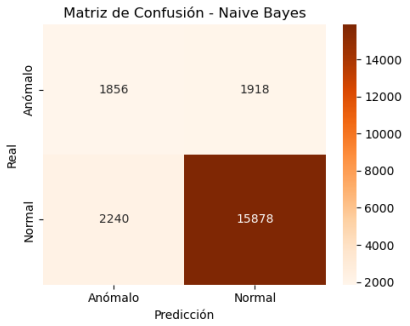


Figura 9: Naive Bayes

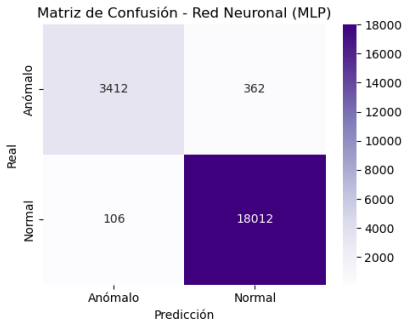


Figura 10: Red Neuronal MLP

4.2. Comparación de modelos

Para resumir los resultados, se presenta la Tabla 3 donde se recogen las métricas de los cuatro modelos evaluados. El análisis confirma que el **MLP** es el mejor modelo, superando el 90 % en todas las métricas y destacando el recall sin sacrificar la precisión. El **Árbol de decisión** también resulta una buena opción, ofreciendo la ventaja de ser interpretable y permitir explicar por qué se clasifica un latido como anómalo o normal. En contraste, el **Naive Bayes**, aunque consigue una alta exactitud, falla en el resto de métricas. Esto se puede corroborar visualmente en la Figura 11, donde el rendimiento del MLP destaca claramente frente a los otros modelos.

Modelo	Accuracy	Precision	Recall	F1-Score
Regresión Logística	90.51 %	84.88 %	54.72 %	0.665
Árbol de Decisión	96.11 %	88.82 %	88.61 %	0.887
Naive Bayes	81.01 %	45.31 %	49.18 %	0.471
MLP	**97.86 %**	**96.99 %**	**90.41 %**	**0.936**

Tabla 3: Comparativa de modelos de clasificación

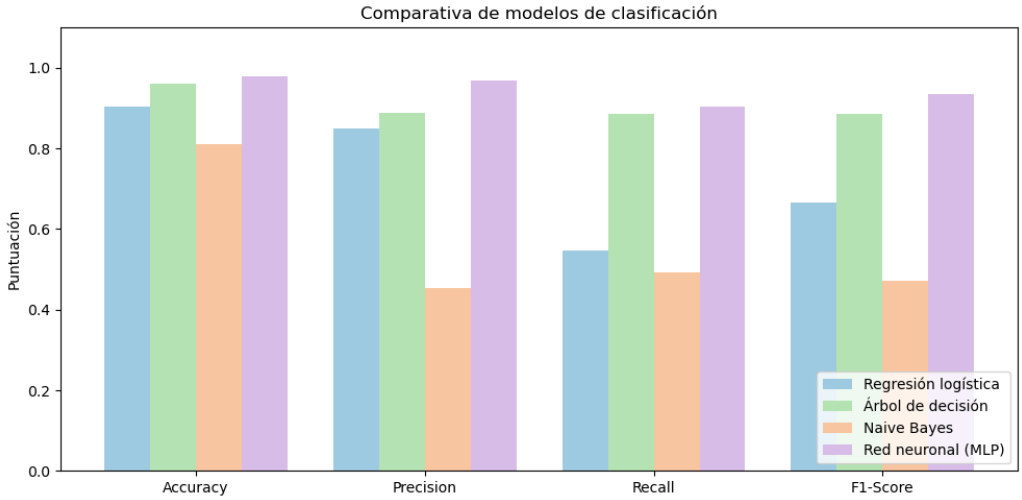


Figura 11: Comparativa de métricas entre modelos

5. Teorema de Bayes

En esta sección se aplica el Teorema de Bayes para estimar la probabilidad de que un latido sea anómalo dada una característica observable en la señal. Esto con el objetivo de observar cómo la presencia de ciertos "síntoma"(patrón) actualiza la creencia sobre la condición del paciente.

5.1. Probabilidades marginales

Partiendo del conjunto de entrenamiento (87 554 registros), se establecen las probabilidades a priori basadas en la frecuencia de aparición de cada clase. Estas representan la probabilidad de

encontrar un latido de cierto tipo antes de analizar cualquier característica adicional. Como se detalla en la columna *Priori* de la Tabla 4, existe un claro desbalance, con una probabilidad de anomalía del 17.23 %.

5.2. Definición del patrón observable

Para este análisis, se ha seleccionado como evidencia la **variabilidad de la señal**, medida a través de su desviación estándar. Se define el evento X como:

$$X : \text{El latido presenta una desviación superior a la mediana del dataset } (\sigma \geq 0{,}1808)$$

Esta elección se basa en la observación de que los latidos anómalos tienden a mostrar mayor variabilidad en promedio ($\bar{\sigma}_{anomalo} = 0{,}2265$) que los normales ($\bar{\sigma}_{normal} = 0{,}1866$).

Las **verosimilitudes**, presentadas en la Tabla 4, indican que es mucho más probable observar el patrón en un latido anómalo (71.09 %) que en uno normal (45.61 %).

5.3. Probabilidades condicionales

Para aplicar el Teorema de Bayes, primero se debe calcular la probabilidad total de observar el patrón, definido en la Ecuación 1.

$$P(X) = P(X|Normal) \cdot P(Normal) + P(X|Anomalo) \cdot P(Anomalo) \tag{1}$$

$$P(X) = (0{,}4561 \cdot 0{,}8277) + (0{,}7109 \cdot 0{,}1723) = 0{,}5000$$

Aplicando el Teorema de Bayes (Ecuación 2), se obtienen las **probabilidades a posteriori** mostradas en la última columna de la Tabla 4.

$$P(\text{Clase}|X) = \frac{P(X|\text{Clase}) \cdot P(\text{Clase})}{P(X)} \tag{2}$$

Clase	**Muestras**	**Priori** $P(C)$	**Verosimilitud** $P(X\|C)$	**Posteriori** $P(C\|X)$
Normal	72,471	0.8277	0.4561	0.7551
Anómalo	15,083	0.1723	0.7109	0.2449

Tabla 4: Resumen de probabilidades.

5.4. Análisis de resultados

La Figura 12 ilustra el cambio entre las probabilidades a priori y a posteriori, en ambas clases. El análisis muestra que la presencia del patrón de alta variabilidad aumenta la probabilidad de que

un latido sea anómalo desde un **17.23 %** hasta un **24.49 %**. Aunque el patrón es informativo,

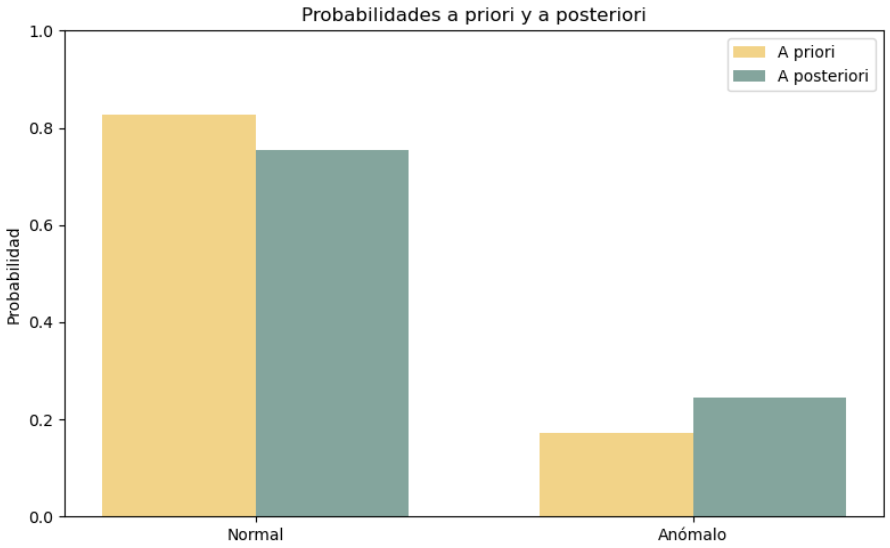


Figura 12: Comparación de probabilidades a priori y a posteriori

no es determinante por sí solo. A pesar de tener *síntomas* de alta variabilidad, la probabilidad posterior indica que sigue siendo más probable (75,51 %) que el latido sea normal. Esto se debe al fuerte **desbalance de clases**: la cantidad absoluta de latidos normales es tan grande que, incluso con una tasa menor de variabilidad, siguen superando en número a los anómalos.

6. Conclusiones

El objetivo de este trabajo fue desarrollar un clasificador capaz de distinguir entre latidos cardíacos normales y anómalos. El análisis exploratorio inicial (EDA) permitió identificar un fuerte desbalance de clases, con una presencia muy superior de latidos normales (82.77 %). Esta desproporción condicionó desde el principio el comportamiento de los modelos, especialmente aquellos basados en supuestos probabilísticos o lineales, que tendieron a favorecer la clase mayoritaria.

En la fase de análisis de componentes principales (PCA), se decidió no estandarizar la señal para preservar su morfología original, dado que se trata de una señal temporal con variabilidad limitada entre muestras. La proyección resultante, mostró un solapamiento notable entre clases, lo que confirmó que los latidos normales y anómalos comparten patrones estructurales muy similares en el espacio lineal. Este resultado anticipó que los clasificadores lineales no serían capaces de separar correctamente ambas categorías.

La evaluación de los modelos corroboró esta hipótesis. Entre los cuatro modelos entrenados, el Perceptrón Multicapa (MLP) fue el que mejor rendimiento alcanzó, gracias a su capacidad para capturar relaciones no lineales y patrones complejos. El Árbol de Decisión, aunque menos preciso, se mostró como alternativa razonable por su interpretabilidad. En contraste, Naive Bayes

obtuvo los peores resultados, debido a la suposición de independencia entre puntos temporales, incompatible con la naturaleza secuencial de la señal ECG.

Finalmente, se probó la posibilidad de definir reglas de decisión basadas en el Teorema de Bayes. El análisis de la variabilidad de la señal permitió identificar un patrón que, en término de verosimilitud, es más frecuente en latidos anómalos que en los normales. Sin embargo, el peso de las probabilidades a priori, dominado por la enorme proporción de latidos normales, limitó su utilidad. Incluso cuando un latido cumple el patrón, la probabilidad posterior de anomalía sigue siendo baja (24.49 %). Esto evidencia que los umbrales univariantes no son suficientes para abordar el problema y refuerza la necesidad de modelos multivariantes como el MLP.

6.1. Líneas futuras

Para mejorar la capacidad del clasificador y superar las limitaciones actuales, se proponen las siguientes líneas de mejora:

- **Gestión del desbalance:** Implementar técnicas de aumento de datos o generación de datos sintéticos para equilibrar las clases antes del entrenamiento, evitando que los modelos se sesguen hacia la clase normal.
- **Modelos especificos para series temporales:** Dado que el ECG es una señal secuencial, sería conveniente probar con arquitecturas de aprendizaje profundo diseñadas para capturar dependencias temporales, como Redes Neuronales Recurrentes (LSTM o GRU).
- **Aprendizaje de características:** Probar el uso de Redes Neuronales Convolucionales (CNN) para extraer características morfológicas de manera automática; a diferencia del MLP, que trata cada punto como una característica independiente.

7. Referencias

[1] S. Fazeli, M. Kachuee, and M. Sarrafzadeh, "Ecg heartbeat classification: A deep transferable representation," *arXiv preprint arXiv:1805.00794*, 2018.

[2] M. Kachuee, S. Fazeli, and M. Sarrafzadeh, "Ecg heartbeat categorization dataset." Kaggle, 2018. Disponible en: `https://www.kaggle.com/datasets/shayanfazeli/heartbeat`.

[3] Universidad Alfonso X el Sabio, "Material docente de matemáticas y estadística para la ia." Aula Virtual UAX, 2024.

8. Anexos

A. Morfología de las señales

La Figura A.13 muestra la superposición de las señales para cada clase:

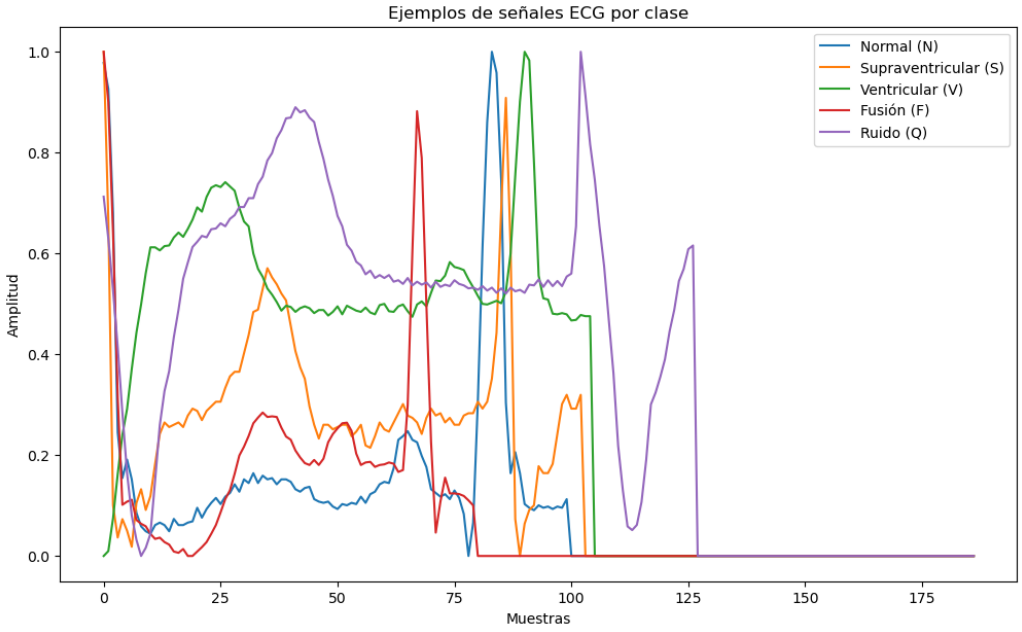


Figura A.13: Ejemplos representativos de señales ECG por clase.

- **Normal (Azul)**: Se distingue por tener un pico central alto, muy estrecho y definido. Sube y baja muy rapido.
- **Supraventricular (Naranja)**: Visualmente es casi idéntica a la normal, su pico es fino. Esta similitud explica por qué a los modelos les costará distinguir entre ambas clases.
- **Ventricular (Verde)**: Es la más diferente. En lugar de un pico fino, muestra una "montaña.ªncha, que tarda mucho en bajar.
- **Fusión (Rojo) y Ruido (Morado)**: Son señales más caóticas e inestables, con formas raras que no siguen el patrón limpio del latido normal.

B. Análisis detallado de la proyección PCA por clase

Debido al alto grado de solapamiento observado en la proyección global, se presenta en la Figura B.14 un desglose individual de cada clase. Esta visualización permite identificar patrones estructurales únicos:

- **Normal (N):** Ocupa la mayor área del espacio, concentrándose en una estructura cónica que se abre hacia la derecha. Su omnipresencia explica la facilidad con la que anomalías sutiles pueden confundirse con variantes normales.

- **Supraventricular (S):** Al aislarla, se observa que no es una nube uniforme, sino que presenta una distribución **multimodal**. Se distinguen al menos dos núcleos principales y una estela diagonal inferior, sugiriendo que esta categoría agrupa subtipos morfológicos distintos.
- **Ventricular (V):** Muestra una dispersión amplia similar a la Normal, pero difusa. Se extiende hacia la zona superior derecha. A diferencia del ruido, no está compactada, reflejando la gran variabilidad morfológica de los latidos ventriculares.
- **Fusión (F):** Sus puntos se alinean en una **trayectoria diagonal compacta** en la zona inferior izquierda ($PC1 < 0, PC2 < 1$), comportándose casi como una variedad lineal unidimensional.
- **Ruido (Q):** Se manifiesta como una nube densa y central, mucho más compacta que las arritmias fisiológicas, lo que denota características estructurales muy consistentes (y anómalas) en comparación con los latidos reales.

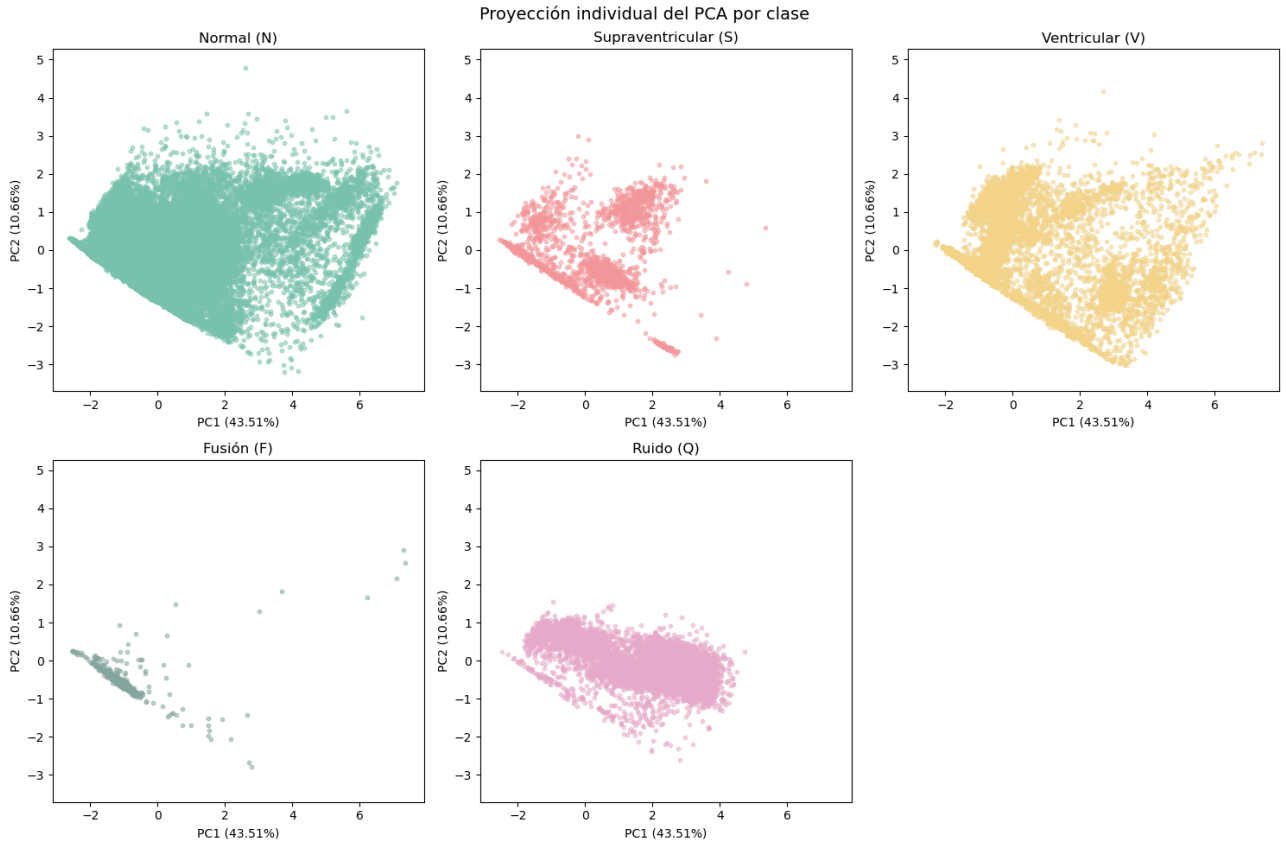


Figura B.14: Desglose de la proyección PCA por clase individual.